

Memoria Técnica: Asistente Smart Home con IA Híbrida (NLU + RAG)

1. Introducción y Caso de Uso

Este proyecto presenta un **Asistente de Voz Inteligente** diseñado para el soporte técnico de ecosistemas Smart Home. La solución utiliza un **Modelo Híbrido** que combina la robustez de la NLU tradicional de **Dialogflow ES** con la flexibilidad de la IA Generativa mediante **RAG**.

Público Objetivo


El sistema está dirigido a usuarios domésticos de dispositivos Smart Home (bombillas, termostatos, cámaras) que buscan una asistencia técnica inmediata y natural, sin necesidad de navegar por menús complejos o manuales extensos.

Justificación Tecnológica

- Dialogflow ES:** Elegido por su estabilidad en la gestión de **Contextos** y **Slot Filling**, fundamental para procesos transaccionales seguros.
- FastAPI:** Proporciona un backend asíncrono de alto rendimiento para gestionar los webhooks y las llamadas a los LLMs con latencia mínima.
- ChromaDB + HuggingFace Local:** Se optó por una base de datos vectorial local y el modelo **all-MiniLM-L6-v2** para garantizar la privacidad de los datos y eliminar la dependencia de APIs externas para embeddings.
- Gemini 1.5 Flash-lite:** Seleccionado específicamente por su velocidad de inferencia, crucial para mantener una conversación de voz fluida y evitar el timeout de 5s de Dialogflow.

2. Diagrama Arquitectónico

La arquitectura se basa en un flujo de datos que integra servicios de nube (Azure/GCP) con un backend local de alta velocidad.



3. Servicios de Voz (Bloque B - Independencia Total)

En estricto cumplimiento de los requisitos de diseño, el sistema implementa una **integración externa de voz** totalmente desacoplada del motor nativo de Dialogflow:

- **Speech-to-Text (STT):** El cliente captura el audio localmente y utiliza **Azure Cognitive Services** para la transcripción en tiempo real con alta precisión.
- **Text-to-Speech (TTS):** La síntesis de respuestas emplea la voz neuronal **es-ES-ElviraNeural** de **Azure Speech Services**, asegurando una prosodia natural y conversacional.

Nota Arquitectónica: No se utilizan las funciones nativas de voz de Dialogflow para garantizar la flexibilidad del ecosistema y cumplir con la exigencia de integración de servicios externos.

4. Flujo de Conversación y Gestión de Contextos

El sistema utiliza **Contextos de Salida** para gestionar conversaciones multi-turno complejas. Un ejemplo crítico es el flujo de vinculación o reporte de incidencias:

1. El usuario inicia una acción (ej: "*Quiero reportar un fallo*").
 2. Dialogflow activa el contexto de sesión **esperando_id**.
 3. Durante la vigencia de este contexto, el sistema prioriza algorítmicamente la captura de la entidad **@id_dispositivo**.
 4. El árbol de diálogo solo avanza cuando el *slot* es validado, garantizando la integridad de la intención original.
-

5. Validación por Regex y Seguridad Transaccional

Para garantizar la integridad de los datos técnicos inyectados en el sistema, se implementan entidades con validación estricta basada en **Expresiones Regulares (Regex)**:

- **@id_dispositivo:** Definida como **\d{6}**. Obliga al usuario a proporcionar exactamente 6 dígitos numéricos, mitigando errores de transcripción STT durante el emparejamiento de hardware.

- **@ticket_id:** Definida como `TK-\d{4}`. Asegura que el seguimiento de incidencias cumpla sistemáticamente con el estándar corporativo.
-

6. Pipeline RAG (Retrieval-Augmented Generation)

La capacidad de resolución técnica autónoma recae sobre un pipeline RAG estructurado en cuatro fases:

1. **OCR Avanzado:** Uso de **Azure Document Intelligence** para la extracción estructurada de texto desde manuales PDF complejos (interpretación de tablas y columnas).
2. **Vectorización Local:** Los textos se fragmentan (*chunking*) en bloques de 500 caracteres y se vectorizan con el modelo local `all-MiniLM-L6-v2`.
3. **Búsqueda Semántica:** **ChromaDB** actúa como base de conocimiento, recuperando en milisegundos los *chunks* más relevantes.
4. **Generación con LLM:** **Gemini 1.5 Flash-lite** recibe el contexto y sintetiza una respuesta técnica breve, diseñada acústicamente para ser reproducida por el motor TTS.

6.1. Gestión de Alucinaciones (Safety Guard)

Para asegurar la robustez de las respuestas técnicas, se implementa un filtro de calidad estricto:

- **Restricción de Contexto:** El *System Prompt* fuerza al LLM a derivar su respuesta **exclusivamente** de los fragmentos recuperados en ChromaDB.
 - **Respuesta de Fallback Seguro:** Si la distancia vectorial no aporta información concluyente, el modelo retorna por defecto: *"Lo siento, no he encontrado instrucciones específicas para ese equipo en los manuales"*, impidiendo la generación de instrucciones técnicas potencialmente destructivas.
-

7. Matriz de Casos de Prueba (QA)

A continuación, se detalla la batería de pruebas de certificación ejecutadas sobre el sistema:

7.1. Bloque: Consultas Técnicas RAG

Test ID	Escenario de Prueba	Input del Usuario	Resultado Esperado Validado
TC-3.1	Selección de Menú	"Manual de usuario"	El bot despliega el menú numérico (1-5) correctamente.
TC-3.2	Consulta RAG	"La 2 (EZVIZ)"	Extrae y sintetiza instrucciones de la cerradura EZVIZ.
TC-3.3	Cache Hit	Repetir "La 2"	Respuesta instantánea (<100ms) servida desde caché.

7.2. Bloque: Flujos Transaccionales

Test ID	Escenario de Prueba	Input del Usuario	Resultado Esperado Validado
TC-4.1	Slot Filling	"Quiero vincular"	El bot retiene el contexto y solicita el ID de 6 dígitos.
TC-4.2	Validación Regex	"Es el 123456"	ID capturado, validado por regex y vinculación completada.
TC-8.1	Follow-up Seguro	"Resetear" → "Sí"	Confirmación de acción crítica tras doble verificación explícita.

8. Conclusión

La solución implementada demuestra empíricamente cómo la orquestación de servicios cognitivos de voz, NLU transaccional (Dialogflow ES) y modelos de lenguaje modernos (FastAPI + Gemini) transforma el soporte técnico clásico. Se logra una experiencia conversacional fluida, precisa y altamente escalable, mitigando el riesgo de alucinación mediante un pipeline RAG local y seguro.